

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2501
**PREDVIĐANJE POTROŠNJE ELEKTRIČNE
ENERGIJE NA SVEUČILIŠTU U ZAGREBU**
FAKULTETU ELEKTROTEHNIKE I
RAČUNARSTVA VIŠESLOJNOM
PERCEPTRONSKOM NEURONSKOM
MREŽOM

Hrvoje Novak

Zagreb, srpanj 2012.

Zahvaljujem se doc. dr. sc. Mariju Vašku na pruženoj prilici i povjerenju za izradu ovog rada te mag. ing. el. Marku Gulinu na pruženoj pomoći i stručnim savjetima. Također, zahvaljujem prof. dr. sc. Tomislavu Tomiši, prof. dr. sc. Željku Tomšiću i doc. dr. sc. Zdenku Šimiću na ustupanju podataka o potrošnji na Fakultetu elektrotehnike i računarstva, kao i Državnom hidrometeorološkom zavodu na ustupanju meteoroloških podataka.

SADRŽAJ

1 Uvod	1
2 Predikcija potrošnje električne energije	2
2.1 Važni čimbenici predikcije potrošnje	3
2.2 Metode predikcije	3
2.2.1 Metode kratkoročnog predviđanja	3
2.2.2 Metode srednjoročnog i dugoročnog predviđanja	6
3 Identifikacija modela potrošnje električne energije	8
3.1 Neuronske mreže	8
3.1.1 Biološka osnova i povijesni razvoj neuronskih mreža	9
3.1.2 Statički modeli neurona	11
3.1.3 Nelinearna aktivacijska funkcija	12
3.2 Višeslojne perceptronske (MLP) neuronske mreže	12
3.3 Algoritmi učenja neuronskih mreža	14
3.3.1 Kriterij kakvoće	15
3.3.2 Levenberg-Marquardtov algoritam	15
4 Rezultati identifikacije	20
5 Zaključak	24
Sažetak	26
Abstract	27

Uvod

Uloga gradova u elektroenergetskom sustavu postaje sve kompleksnija uslijed porasta broja stanovnika, utjecaja klimatskih promjena i potrebe za povećanjem sigurnosti opskrbe električnom energijom. Kako bi se ti uvjeti zadovoljili potrebno je započeti prilagođavanje gradova u svim aktivnostima upravljanja energijom, započevši s poboljšanjem energetske učinkovitosti u zgradarstvu. Predikcija ponašanja sustava ima vrlo važnu ulogu u upravljanju svim vrstama dinamičkih sustava, te posebice dolazi do izražaja kod upravljanja energetskim sustavima, poput plinskog ili elektroenergetskog sustava, gdje poznavanje budućeg opterećenja mreže može direktno utjecati na kvalitetu upravljanja cjelokupnim sustavom na dnevnoj bazi. Primjerice, kako se električna energija ne može pohranjivati u većim količinama, predikcija opterećenja uvelike može pomoći planiranju proizvodnje i/ili kupnje električne energije i na taj način omogućiti značajne financijske i energetske uštede. Osnovna namjena istraživanja i predikcije opterećenja jest: (i) planiranje energetskih tokova lokalno (mikromreža) i na razini elektroenergetskog sustava, posebice radi, (ii) pomoći pri procjeni sigurnosti djelovanja elektroenergetskog sustava, i (iii) pomoći pri upravljanju samim sustavom (operatorima u upravljačkim centrima) [6].

U prvom poglavlju dani su motivi za predikciju potrošnje električne energije. U drugom poglavlju pojašnjena je metodologija identifikacije modela pomoći umjetnih neuronskih mreža. U trećem poglavlju prikazani su rezultati identifikacije modela potrošnje električne energije. Za strukturu modela potrošnje električne energije odabrana je višeslojna perceptronska neuronska mreža, implementirana na temelju raspoloživih mjerjenja potrošnje električne energije na Fakultetu elektrotehnike i računarstva i dostupnih meteoroloških podataka iz automatske mjerne postaje Zagreb-Maksimir, za 2011. godinu.

Predikcija potrošnje električne energije

Precizni modeli za predikciju potrošnje električne energije ključni su za upravljanje i rad elektroenergetskih sustava. Predikcija potrošnje pomaže pri donošenju važnih odluka, uključujući i odluke o proizvodnji i kupnji električne energije, razvoju infrastrukture i povećanju sigurnosti opskrbe električnom energijom. Predikciju potrošnje možemo podjeliti u tri kategorije: (i) kratkoročna predikcija (uobičajeno u vremenskom razmaku od jednog sata do jednog tjedna), (ii) srednjoročna predikcija (od jednog tjedna do jedne godine) i (iii) dugoročna predikcija (duža od jedne godine) [2]. Osim što je svaka od kategorija primjenjena za različite vrste upravljanja elektroenergetskim sustavima, one se također razlikuju i u preciznosti. Tako na primjer možemo za slijedeći dan predvidjeti potrošnju u određenom području s točnošću reda 1-3%, dok je tako nešto nemoguće u dugoročnim predviđanjima pošto ne postoje točne vremenske prognoze za jednogodišnja ili duža razdoblja. Za duža razdoblja moguće je predvidjeti vremenski normaliziranu potrošnju električne energije za koju uzimamo prosječne godišnje vremenske uvijete dobivene kroz period od 25-30 godina na danom području.

Predviđanje potrošnje je od velike važnosti za planiranje i upravljanje elektroenergetskim sustavom. Pod utjecajem promjena ponude i potražnje energije, vremenskih uvjeta i porasta cijena električne energije od 10 ili više puta za vrijeme vršnih opterećenja, predviđanje potrošnje dobiva na dodatnoj važnosti. Kratkoročna predviđanja pomažu pri procjenama toka energije što uvelike može umanjiti broj preopterećenja, povećati stabilnost opskrbe i reducirati zatajenja opreme i ispadne iz mreže. Većina metoda predikcije opterećenja koristi statističke metode ili algoritme s umjetnom inteligencijom poput regresije, neuronskih mreža, neizrazite logike i ekspertnih sustava.

2.1 Važni čimbenici predikcije potrošnje

Za kratkoročna predviđanja potrebno je uzeti u obzir vremenske periode, meteorološke prognoze i moguće skupine potrošača. Kod srednjoročnih i dugoročnih predviđanja povijesne podatke o potrošnji i vremenu, podatke o broju potrošača pojedine skupine, potrošačke aparate na području predviđanja, demografske podatke i mnoge druge.

Vremenski podatci uključuju godišnje doba, dan u tjednu te sat u danu. Značajne su razlike u potrošnji prilikom ranih dana te vikenda, također i među danima u tjednu. Bitne promjene donosi i ljetno razdoblje kada se zbog viših temperatura javlja porast upotrebe rashladnih uređaja, te također doba praznika koja su iznimno nepredvidiva. Tablični prikaz nekih od važnijih čimbenika koji utječu na potrošnju električne energije prikazan je u Tablici (2.1) [1].

Najznačajniji od svih uvjeta su klimatski uvjeti. U obzir ulaze razni klimatski čimbenici od kojih su temperatura i vlažnost najvažniji. U pregledu 22 izvještaja predviđanja potrošnje električne energije pokazano je da ih je trinaest kao parametar koristilo samo temperaturu, troje temperaturu i vlažnost, troje je koristilo druge klimatske čimbenike, a troje samo parametre opterećenja [4]. Među klimatskim čimbenicima često se koriste dvije kompozitne varijable, THI¹ i WCI², koji predstavljaju ljetne i zimske klimatske utjecaje, tim redom. Također, jedan od važnijih čimbenika jest sunčeva dozračenost koja može bitno pridonijeti kvaliteti predikcije.

2.2 Metode predikcije

U posljednjih nekoliko desetljeća razvijeno je nekoliko metoda za predikciju potrošnje električne energije. Metode krajnje namjene i ekonometrijskog pristupa koriste se pri srednjoročnom i dugoročnom predviđanju, dok se veliki broj metoda poput pristupa sličnog dana, neuronskih mreža, ekspertnih sustava i neizrazite logike koristi pri kratkoročnoj predikciji.

2.2.1 Metode kratkoročnog predviđanja

Među brojnim metodama koje se koriste pri kratkoročnom predviđanju važno je istaknuti:

- Pristup "sličnog" dana³. Pristup koji se temelji na traženju povijesnih podataka

¹engl. Temperature-Humiditiy Index (THI)

²engl. Wind-Chill Index (WCI)

³engl. Similar-day approach

Tablica 2.1: Utjecajni čimbenici za potrošnju energije

Vremenski čimbenici	Godišnja doba (ljeto, zima itd.) Doba dana (jutro, večer, noć itd.) Dan u tjednu Praznici (Božić, Nova godina itd.)
Ekonomski i ekološki čimbenici	Demografske karakteristike potrošača (ruralne sredine, rezidencijalne itd.) Ekonomski trendovi (recesija ili pak ekspanzija) Promjena cijene električne energije Industrijski rast
Meteorološki čimbenici	Temperatura Sunčeva dozračenost Vlažnost zraka Brzina vjetra Padaline (kiša, tuča, snijeg) Naoblaka Olujna nevremena
Nasumični čimbenici	Pokretanje ili zaustavljanje rada velikih potrošača (čeličana, tvornica, elektrana itd.) Sportski događaji Popularne televizijske emisije i serije Grmljavine i olujna nevremena

za dane unutar jedne, dvije ili tri unazadne godine sličnih karakteristika danu čiju potrošnju energije predviđamo. Umjesto jednog "sličnog" dana može se koristiti linearna kombinacija više "sličnih" dana.

- Regresijske metode. Regresija je jedna od najšire korištenih statističkih metoda. Pri predikciji potrošnje regresijske metode koriste se pri modeliranju odnosa između potrošnje energije i drugih čimbenika poput vremena, skupine potrošača i vrste dana. Mnogi modeli koriste determinističke utjecaje poput praznika, statističke utjecaje poput prosječne potrošnje energije i vanjske utjecaje poput temperature.
- Neuronske mreže. Uporaba umjetnih neuronskih mreža kao metode predviđanja potrošnje energije proučavana je još od 1990. godine [2]. Najpopularnije umjetne neuronske mreže za predviđanje opterećenja su mreže s unazadnjim ras-

prostiranjem. Neuronske mreže s unazadnjim rasprostiranjem koriste kontinuirane funkcije i nadzirano učenje. Kod tih se mreža podešavanjem unutarnjih parametara aproksimira funkcija potrošnje energije. Podešavanje unutarnjih parametara odvija se pri učenju neuronske mreže pomoću algoritama učenja koji zahtijevaju ulazne i izlazne podatke. Najčešće se kao ulazni podaci koriste vremenski podaci, podaci vezani uz godišnja doba, ili povjesna mjerenja potrošnje energije, dok se kao izlazni podaci koriste stvarne vrijednosti potrošnje energije.

- Ekspertni sustavi. Ekspertni sustavi temelje se na korištenju pravila, često heurističkih u svojoj prirodi kako bi dali točna predviđanja. Ekspertni sustavi koriste pravila i procedure korištene od strane stručnjaka u interesnom području koje se zatim uklapaju u programe sposobne činiti predviđanja bez ljudske pomoći. Uporaba ekspertnih sustava započela je 1960-ih godina u primjenama za geološka ležišta i računalni dizajn. Ekspertni sustavi daju najbolje rezultate kada stručnjaci iz danog područja surađuju s programskim inženjerima uklapajući za to vrijeme stručno znanje u upravljački program. Isto tako, stručno znanje mora biti prikladno za ugradnju u softverska pravila (tj. stručnjak mora biti u stanju objasniti svoj proces odlučivanja programeru). Ekspertni sustavi mogu ugraditi stotine ili tisuće proizvodnih pravila.
- Neizrazita logika⁴. Neizrazita logika je poopćenje uobičajene Booleove logike korištene za dizajniranje digitalnih krugova. U Booleovoj logici ulazne vrijednosti mogu poprimiti dvije vrijednosti, "0" i "1". U neizrazitoj logici ulazne vrijednosti poprimaju vrijednosti u kvalitativnim rasponima. Tako na primjer transformatorsko opterećenje može poprimiti "nisku", "srednju" i "visoku" vrijednost [2]. Neizrazita logika omogućuje logičko zaključivanje izlaza temeljeno na neizrazitim ulazima. Među prednostima neizrazite logike ističe se nedostatak potrebe za matematičkim modelom mapiranja ulaza u izlaze i nedostatak potrebe za preciznim ulazima. S takvim generičkim uređenjem pravila, ispravno projektiran sustav neizrazite logike može biti veoma robustan kada se koristi za predviđanje opterećenja. Naravno, u mnogim je situacijama potreban egzaktan izlaz (npr. točno opterećenje u 12:00 sati). Nakon logičke obrade neizrazitih ulaza, "defuzzification" proces se može koristiti za predviđanje takvih preciznih izlaza.
- Metoda potpornih vektora⁵ su novije napredne tehnike za rješavanje klasifikacij-

⁴engl. Fuzzy logic

⁵engl. Support Vector Machines (SVMs)

skih i regresijskih problema. Za razliku od neuronskih mreža, koje pokušavaju definirati složene funkcije u prostoru ulaza, metode potpornih vektora obavljaju nelinearno mapiranje (pomoću tzv. kernel funkcije) podataka u više dimensionalni prostor. Zatim se koriste jednostavne linearne funkcije za stvaranje linearnih granica u novom prostoru. Problem odabira strukture za neuronske mreže ovdje zamjenjuje problem izbora odgovarajuće kernel funkcije.

2.2.2 Metode srednjoročnog i dugoročnog predviđanja

Metode krajnje namjene i ekonometrijskog pristupa te njihove kombinacije najčešće su metode pri srednjoročnom i dugoročnom predviđanju. Opisi uređaja koje koriste kupci, veličine kuća, starosti opreme, promjene tehnologija, ponašanje kupaca, i dinamika populacije obično su uključeni u statističke i simulacijske modele temeljene na metodama krajnje namjene. Osim toga, ekonomski faktori kao što su dohodak po stanovniku, razina zaposlenosti i cijene električne energije su uključeni u ekonometrijske modele. Ovi modeli su često korišteni u kombinaciji s metodama krajnje namjene. Dugoročne prognoze uključuju prognoze o promjenama stanovništva, gospodarskom razvoju, industrijskoj izgradnji i razvoju tehnologije.

- Modeli krajnje namjene⁶. Pristup krajnje namjene izravno procjenjuje potrošnju energije pomoću opsežnih informacija o krajnjoj uporabi i krajnjim korisnicima, poput uređaja koje koriste kupci, njihove starosti, veličine kuća, itd. Statistički podaci o kupcima uz dinamičke promjene su osnova za prognozu. Modeli krajnje namjene usredotočeni su na razne namjene električne energije u stambenim, komercijalnim i industrijskim sektorima. Ovi modeli temelje se na principu dobivanja potrošnje električne energije iz potražnje kupaca za svjetlom, hlađenjem, grijanjem, itd. Takvi modeli objašnjavaju potrošnju energije kao funkciju broja uređaja na tržištu. U idealnom slučaju ovaj je pristup vrlo precizan. Međutim, osjetljiv je na količinu i kvalitetu podataka krajnje namjene. Tako npr. u ovoj metodi je starost distribucijske opreme vrlo važna za pojedine vrste uređaja. Predviđanje opterećenja metodom krajnje namjene zahtijeva manje povijesnih podataka, ali više informacija o korisnicima i njihovoj opremi.
- Ekonometrijski modeli. Ekonometrijski pristup kombinira ekonomsku teoriju i statističke metode za predviđanje potrošnje električne energije. Pristup procjenjuje odnos između potrošnje energije i čimbenika koji utječu na potrošnju. Od-

⁶engl. End-use models

nosi se procjenjuju po kriteriju najmanjih kvadrata ili metodom vremenskih serija. Jedna od mogućnosti u tom okviru je objedinjenje ekonometrijskog pristupa, kada se potrošnja u različitim sektorima (stambeni, komercijalni, industrijski, itd.) izračunava kao funkcija vremena, gospodarskih i drugih varijabli, a zatim se procjena sklapa korištenjem novijih povijesnih podataka.

Identifikacija modela potrošnje električne energije

Kako bismo dobili što točniju predikciju potrošnje električne energije na Fakultetu elektrotehnike i računarstva (FER) napravljena je identifikacija modela potrošnje radne i jalove energije kao statičke funkcije vremenskih i meteoroloških podataka. Model je identificiran primjenom MLP neuronske mreže, a ulazno-izlazni podatci potrebni za učenje neuronske mreže preuzeti su iz DHMZ-a¹ i mjerena obavljenih na FER-u kroz 2011. godinu. U spomenutim podacima automatske mjerne postaje Zagreb-Maksimir nalaze se mjerena vrijednosti temperature, relativne vlage, tlaka, sunčeve dozračenosti, oborina i vjetra, od čega su kao ulazni podatak korištena mjerena temperturnih vrijednosti i sunčeve dozračenosti u 10-minutnoj rezoluciji, dok su kao izlazni podaci korištena mjerena potrošnja energije na FER-u za 2011. godinu u 15-minutnoj rezoluciji. Radi numeričke stabilnosti obavljeno je normiranje ulazno-izlaznih podataka, a za učenje neuronske mreže primijenjen je Levenberg-Marquardtov algoritam.

3.1 Neuronske mreže

Pojam *neuronska mreža*² donedavno se uglavnom koristio za referenciranje na mrežu bioloških neurona. Danas se taj pojam sve više odnosi na umjetne neuronske mreže³, tj. mreže sastavljanje od umjetnih neurona i čvorova međusobno povezanih sinaptičkim vezama s pridijeljenim težinskim koeficijentima. Prema tome neuronske mreže dijelimo

¹Državni Hidrometeorološki Zavod (DHMZ)

²engl. Neural Network (NN)

³engl. Artificial Neural Network (ANN)

na dvije velike skupine: (i) biološke i (ii) umjetne neuronske mreže. Istraživanja i razvoj na području umjetnih neuronskih mreža motivirana su spoznajama o građi i načinu funkcioniranja ljudskog mozga te njegovim nevjerljivo velikim sposobnostima u rješavanju složenih problema. Dva su osnovna cilja tih istraživanja: (i) razvoj novih struktura umjetnih neuronskih mreža koje bi funkcionalne na analogan način kao što funkcioniра ljudski mozak i koje bi mogle oponašati barem neke njegove funkcije te (ii) njihova primjena u rješavanju praktičnih problema [5]. Razvijeno je mnoštvo različitih struktura neuronskih mreža koja se u osnovi mogu podijeliti na (i) statičke i (ii) dinamičke neuronske mreže. Područja primjene umjetnih neuronskih mreža su identifikacija modela sustava i upravljanje takvim sustavima, prepoznavanje uzoraka, medicinske dijagnoze itd. Sa stajališta primjene u identifikaciji procesa najvažnija je svojstvo statičkih neuronskih mreža njihova sposobnost aproksimacije proizvoljnih kontinuiranih funkcija.

3.1.1 Biološka osnova i povijesni razvoj neuronskih mreža

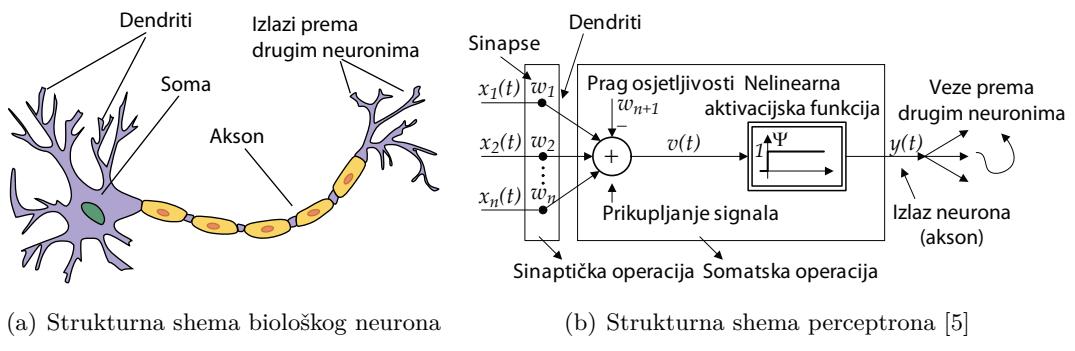
Ljudski se mozak sastoji od oko 10^{11} osnovnih živčanih stanica (neurona) organiziranih u slojeve⁴ međusobno povezanih u složenu mrežu s 10^{15} međusobnih veza. Ovako gusto povezana i moćna biološka neuronska mreža uvjetuje sve čovjekove aktivnosti i njegovo ponašanje te osigurava izuzetno veliku računsku i memorijsku moć. Biološki neuron, kao osnovna gradivna jedinica biološke neuronske mreže, može se pojednostavljeno prikazati kao stanica sastavljena od tijela (soma), mnoštva dendrita i aksona. Signali se od sinapsi (poveznice između dva neurona) proslijeduju dendritima do tijela neurona gdje se prikupljaju i obrađuju. Ovi signali mogu za tijelo neurona biti pobudjući⁵ ili smirujući⁶ i matematički gledano suprotnoga su predznaka. Ako je njihova kumulativna vrijednost veća od praga osjetljivosti neurona, tijelo neurona generirati će impulse koji će se duž aksona poslati prema drugim neuronima. U suprotnom slučaju neuron će ostati nepobuđen i neće odaslati impulse. Na osnovi ovog opisa obrada signala u neuronu odvija se kroz dvije odvojene operacije: (i) *sinaptička operacija* koja daje težinu ulaznim signalima u neuron i (ii) *somatska operacija* koja prikuplja "otežane" signale i uspoređuje njihovu kumulativnu vrijednost s pragom osjetljivost.

Početci umjetnih neuronskih mreža pojavili su se u radovima koje su objavili McCulloch i Pitts (1943. i 1947. godine) gdje su koristili jednostavan model neurona naziva

⁴engl. layers

⁵engl. excitatory

⁶engl. inhibitory



Slika 3.1: Biološki neuron i perceptron

perceptron koji poput biološkog obrađuje signale sinaptičkom i somatskom operacijom. Sinaptička operacija odnosi se na otežavanje ulaznih signala x_i težinskim koeficijentima w_i koji se zatim u somatskoj operaciji zbrajaju i njihov se zbroj upoređuje s pragom osjetljivosti neurona w_{n+1} . Ako je zbroj veći nelinearna aktivacijska funkcija ψ generira izlaz neurona y iznosa 1, dok je u suprotnome izlaz jednak 0. 1959. godine Frank Rosenblat je primjenom Hebbianovog algoritma za podešavanje sinaptičkih težinskih koeficijenata perceptrona i tako napravio prvu umjetnu neuronsku mrežu koja je imala sposobnost učenja. U svome je radu 1962. godine dokazao značajan teorem o učenju perceptrona [3]: *Perceptron može naučiti sve što može predstaviti.* Predstavljanjem se smatra sposobnost aproksimiranja određene funkcije, dok je učenje postupak koji sustavnim podešavanjem parametara mreže postiže zadovoljavajuću aproksimaciju te funkcije. Bernard Widrow i Ted Hoff su 1960. godine umjesto diskontinuirane primijenili kontinuiranu linearnu aktivacijsku funkciju a za podešavanje težinskih koeficijenata primijenili su algoritam najmanjih kvadrata. Sve je ovo dovelo do euforičnih istraživanja u ovome području da bi zatim uslijedilo razočaranje kada je uočena nesposobnost perceptrona pri rješavanju jednostavnih zadataka (primjerice *isključivo ili*). Dokazano je da postoje ozbiljna ograničenja sposobnosti jednoslojnih perceptronskih mreža što je dovelo do zastoja na području razvoja umjetnih neuronskih mreža. Zato je potrajan sve do 1986. godine kada je skupina autora objavila niz rezultata i algoritama o umjetnim neuronskim mrežama, među kojima se najviše isticao algoritam povratnog prostiranja izlazne pogreške⁷ koji je riješio problem učenja višeslojnih neuronskih mreža. Nakon pojave BP algoritma znanstvena je zajednica usmjerila istraživačke aktivnosti u proučavanje i ravoj neuronskih mreža. Glavnina aktivnosti može se svrstati u neka od sljedećih područja: (i) razvoj modela umjetnih neurona, (ii) razvoj struktura

⁷engl. BackPropagation algorithm (BP)

neuronskih mreža (iii) razvoj algoritama učenja (iv) razvoj tehnologija implementacije i sustava zasnovanih na primjeni neuronskih mreža [5].

3.1.2 Statički modeli neurona

Perceptron ima skromne mogućnosti predstavljanja, što je najvećim dijelom posljedica diskontinuiteta aktivacijske funkcije. Diskontinuitet aktivacijske funkcije otežava učenje mreža, jer većina algoritama učenja zahtijeva izračunavanje derivacije aktivacijskih funkcija za podešavanje koeficijenata unutarnjih slojeva mreže. Ta se ograničenja mogu prevladati uporabom kontinuiranih, derivabilnih aktivacijskih funkcija, od kojih se najčešće koriste funkcije koje pripadaju klasi sigmoidalnih funkcija⁸.

Ovako definirani model neurona ne sadrži dinamičke članove, točnije njegov izlaz ovisi isključivo o trenutnim vrijednostima ulaznih signala i težinskim koeficijentima. Stoga se ovaj neuron naziva statičkim neuronom [5]. Opisani neuron predstavlja poopćenje McCulloh-Pittsova perceptrona pa ga se često naziva i perceptronom. Postoji velik broj neuronskih mreža izgrađenih od perceptrona organiziranih u tri ili više slojeva. Te se mreže nazivaju višeslojnim perceptronskim mrežama⁹.

Perceptron se matematički može opisati sljedećim izrazima:

$$v(t) = \sum_{i=1}^m w_i x_i(t) - w_{m+1}, \quad (3.1a)$$

$$y(t) = \psi(v(t)), \quad (3.1b)$$

gdje je x_i ulazni signal, w_i sinaptički težinski koeficijent, w_{m+1} prag osjetljivosti neurona, v ulaz u nelinearnu aktivacijsku funkciju, ψ nelinearna aktivacijska funkcija, a y izlaz neurona.

Ako vektor ulaza proširimo članom $x_{n+1} = 1$, izraz (3.1a) možemo napisati kao:

$$v(t) = \mathbf{w}^\top \mathbf{x}(t), \quad (3.2)$$

Izraz (3.1a) opisuje sinaptičku operaciju i prve dvije somatske operacije (prikljupanje otežanih ulaznih signala i usporedbu njihova zbroja s pragom osjetljivosti). Zajedno te tri operacije čine operaciju konfluencije. Dakle, matematički gledano, umjetni neuron dijelimo na operaciju konfluencije i nelinearnu aktivacijsku funkciju.

⁸Funkcija pripada klasi sigmoidalnih funkcija ako zadovoljava: (i) monotono je rastuća na intervalu od $(-\infty, \infty)$, (ii) simptotski se približava donjoj graničnoj vrijednosti kako teži $-\infty$, odnosno gornjoj kako teži ∞ te (iii) ima samo jednu točku infleksije

⁹engl. MultiLayer Perceptron networks (MLP)

3.1.3 Nelinearna aktivacijska funkcija

Nelinearna aktivacijska funkcija $\psi(v)$ (3.1a), preslikava izlaznu vrijednost operacije konfluencije $v(t)$ u izlazni signal neurona $y(t)$ ograničenog iznosa. Iznos izlaznog signala neurona najčešće je radi numeričke stabilnosti ograničen u području $(0, 1)$ za unipolarne signale odnosno u području $(-1, 1)$ za bipolarne signale. Velik je broj aktivacijskih funkcija koje omogućuju neuronskim mrežama aproksimaciju proizvoljne kontinuirane funkcije, no neke su prihvaćene kao standardne aktivacijske funkcije. Najčešće korištene aktivacijske funkcije su logsig i tansig funkcije dok se kod neurona u izlaznom sloju mreže koristi i linearna aktivacijska funkcija (Tablica 3.1).

Tablica 3.1: Najčešće korištene aktivacijske funkcije kod MLP neuronskih mreža

Naziv funkcije	Izraz za funkciju
Logsig	$\psi(v) = \frac{1}{1 + e^{-g_a v}}$
Tansig	$\psi(v) = \frac{2}{1 + e^{-2g_a v}} - 1$
Linearna (purelin)	$\psi(v) = g_v \cdot v$

Aktivacijsko se pojačanje g_a uobičajeno uzima jediničnog iznosa, no u nekim se radovima predlaže njegovo podešavanje.

3.2 Višeslojne perceptronske (MLP) neuronske mreže

Višeslojne perceptronske neuronske mreže izgrađene su od perceptron organiziranih u serijski povezane slojeve. Slojevi se najčešće označuju brojevima $0, 1, 2, \dots, L$.

Nulti sloj samo proslijeđuje vektor ulaza u mrežu na ulaz prvog sloja što se može opisati sljedećim izrazom:

$$y_0 = x, \quad (3.3)$$

pri čemu je x_i vektor ulaza u mrežu, y_i vektor izlaza iz 0 -toga sloja mreže.

L -ti sloj je ujedno i izlazni sloj mreže, dok se slojevi između njih nazivaju umutarnjim ili skrivenim slojevima (*engl. hidden layers*) jer ne daju i ne primaju vanjske signale. Vektor ulaza se pri ulazu u l -ti sloj mreže proširuje članom $x_{l,n(l-1)+1} = 1$ koji pomnožen odgovarajućim težinskim koeficijentom daje pomak (*engl. bias*) neuronima l -toga sloja. Matematički operaciju konfluencije možemo prikazati kao:

$$x_l = [y_{l-1} 1]^T, \quad 1 \leq l \leq L, \quad (3.4a)$$

$$v_l = W_s \cdot x_l, \quad 1 \leq l \leq L, \quad (3.4b)$$

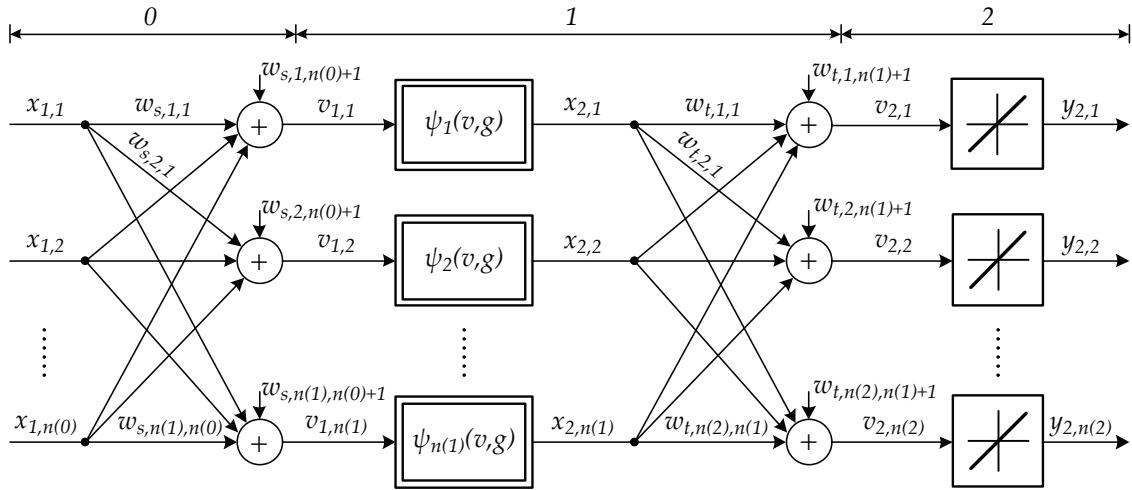
pri čemu su: v_l vektor izlaza operacije konfluencije i W_s matrica težinskih koeficijenata sinaptičkih veza l-tog sloja mreže, dimenzija $n(l) \times (n(l) + 1)$:

$$\mathbf{W}_s = \begin{bmatrix} w_{s,1,1} & \dots & w_{s,1,n(l-1)} & w_{s,1,n(l-1)+1} \\ w_{s,2,1} & \dots & w_{s,2,n(l-1)} & w_{s,2,n(l-1)+1} \\ \vdots & \ddots & \vdots & \vdots \\ w_{s,n(l),1} & \dots & w_{s,n(l),n(l-1)} & w_{s,n(l),n(l-1)+1} \end{bmatrix},$$

Izlaz y_l iz l-tog sloja mreže dobije se propuštanjem vektora v_l kroz aktivacijske funkcije l-tog sloja čiji su uobičajeni primjeri prikazani u Tablici 3.1:

$$y_l = \psi_l(v_l, g), \quad (3.5)$$

gdje je ψ_l vektor aktivacijskih funkcija l-tog sloja, a g parametar aktivacijske funkcije.



Slika 3.2: Strukturalna shema MLP neuronske mreže

Svi neuroni u nekome sloju povezani su sa svim neuronima u dva susjedna sloja preko jednosmjernih, unaprijednih veza. Veza između neurona u istome sloju, ili između neurona koji nisu u susjednim slojevima nema. Veze između neurona susjednih slojeva predstavljene su sinaptičkim težinskim koeficijentima koji djeluju kao pojačala signala na odgovarajućim vezama. Iznosi tih koeficijenata određuju vladanje mreže, odnosno njenu sposobnost aproksimacije nelinearne funkcije. Računanje njihovih odgovarajućih iznosa ostvaruje se algoritmom učenja.

Iako nema teoretskog ograničenja na broj unutarnjih slojeva neurona, uglavnom se koriste MLP mreže s jednim ili dva unutarnja sloja, to jest dvoslojne ili troslojne

MLP mreže. Teoretski je dokazano da MLP mreža s jednim unutarnjim slojem može aproksimirati proizvoljnu, kontinuiranu nelinearnu funkciju.

Nakon definiranja matematičkog modela MLP neuronske mreže, potrebno je još definirati i algoritam učenja. U nastavku je opisan korišteni algoritam učenja neuronske mreže za identifikaciju modela predviđanja potrošnje energije.

3.3 Algoritmi učenja neuronskih mreža

Neuronska je mreža u potpunosti određena tek kada je uz njezinu strukturu definiran i algoritam učenja [5]. Algoritam učenja podešava parametre mreže s ciljem pronalaženja takvih vrijednosti parametara uz koje ona dobro aproksimira zadalu nelinearnu funkciju. Iako je razvijen veliki broj raznih algoritama učenja neuronskih mreža, moguće ih je po načinu učenja mreže podijeliti na algoritme temeljene na pogrešci i algoritme temeljene na izlazu mreže.

Algoritmi učenja temeljni na pogrešci¹⁰ (algoritmi s "učiteljem") zahtijevaju vanjski referentni signal (učitelj) s kojim uspoređuju dobiveni odziv neuronske mreže generirajući zatim signal pogreške. Na temelju tog signala algoritam učenja mijenja sinaptičke težinske koeficijente neuronske mreže s ciljem poboljšanja njezina vladanja, to jest smanjenja pogreške. Ovi se algoritmi mogu primijeniti samo ako je unaprijed poznato željeno vladanje neuronske mreže, to jest podaci za učenje moraju sadržavati parove ulazno-izlaznih signala.

Algoritmi učenja temeljni na izlazu mreže¹¹ (algoritmi bez "učitelja") ne zahtijevaju vanjski referentni signal. Podaci na osnovi koji se mreža uči sadrže samo vrijednosti ulaznih signala u mrežu. Postoji i podvrsta algoritama učenja temeljena na izlazu mreže koja se zasniva na tzv. signalu ojačanja koji daje kvalitativnu ocjenu vladanja mreže. Primjenjuju se u slučajevima kada vanjski referentni signal nije dostupan, ali je dostupan signal koji predstavlja kritičku ocjenu vladanja mreže u smislu "dobro/loše".

Gotovo svi algoritmi učenja neuronskih mreža pripadaju u jednu od ovih kategorija ili su njihova varijacija. U identifikaciji i upravljanju nelinearnim sustavima najčešće je poznato željeno vladanje neuronske mreže, pa se za njezino učenje primjenjuju algoritmi temeljeni na pogrešci.

¹⁰engl. Error-based algorithms

¹¹engl. Output-based algorithms

3.3.1 Kriterij kakvoće

Kriterij kakvoće za učenje neuronske mreže definiran je kao [7]:

$$\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) = \frac{1}{2} e^\top(\mathbf{X}_i, \boldsymbol{\Theta}) e(\mathbf{X}_i, \boldsymbol{\Theta}) = \frac{1}{2} e^2(\mathbf{X}_i, \boldsymbol{\Theta}), \quad (3.6)$$

gdje je \mathbf{X} skup ulaznih podataka, $\boldsymbol{\Theta}$ je vektor parametara neuronske mreže, \mathbf{X}_i je vektor ulaznih podataka u rezoluciji od petnaest minuta, a pogreška e je definirana kao:

$$e(\mathbf{X}_i, \boldsymbol{\Theta}) = f(\mathbf{X}_i, \boldsymbol{\Theta}) - \mathbf{E}_{FER,i}, \quad (3.7)$$

gdje je f funkcija koja opisuje model potrošnje energije na FER-u, \mathbf{X}_i je vektor ulaznih podataka u rezoluciji od petnaest minuta, $\mathbf{E}_{FER,i}$ je vektor mjerena potrošnje radne ili jalove energije na Fakultetu Elektrotehnike i Računarstva.

Ako se u obzir uzme i efekt normiranja ulaznih i izlaznih podataka:

$$\bar{E} = \mu E + v,$$

gdje su \bar{E} normirani podatci, tada je kriterijska funkcija definirana kao:

$$\bar{\mathfrak{J}}(\bar{\mathbf{X}}, \bar{\boldsymbol{\Theta}}) = \frac{1}{2} \bar{e}^\top(\bar{\mathbf{X}}_i, \bar{\boldsymbol{\Theta}}) \bar{e}(\bar{\mathbf{X}}_i, \bar{\boldsymbol{\Theta}}) = \frac{1}{2} \bar{e}^2(\bar{\mathbf{X}}_i, \bar{\boldsymbol{\Theta}}), \quad (3.8)$$

pri čemu je pogreška \bar{e} definirana kao:

$$\bar{e}(\bar{\mathbf{X}}_i, \bar{\boldsymbol{\Theta}}) = \frac{f(\bar{\mathbf{X}}_i, \bar{\boldsymbol{\Theta}}) - v}{\mu} - \frac{1}{\mu} \bar{E}_{FER,i} + \frac{v}{\mu}, \quad (3.9)$$

gdje su $\bar{\mathbf{X}}_i$ normirani ulazni podatci u rezoluciji od petnaest minuta, $\bar{\boldsymbol{\Theta}}$ su normirani parametri modela potrošnje energije, a μ i v su koeficijenti normiranja.

3.3.2 Levenberg-Marquardtov algoritam

Izraz za kriterij kakvoće (3.6) može se u vektorskem zapisu prikazati na sljedeći način:

$$\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) = \frac{1}{2} \mathbf{e}^\top(\mathbf{X}, \boldsymbol{\Theta}) \mathbf{e}(\mathbf{X}, \boldsymbol{\Theta}), \quad (3.10)$$

gdje je $\mathbf{e}(\mathbf{X}, \boldsymbol{\Theta})$ vektor pogrešaka na čitavom skupu mjernih podataka:

$$\mathbf{e}(\mathbf{X}, \boldsymbol{\Theta}) = \begin{bmatrix} e(\mathbf{X}_1, \boldsymbol{\Theta}) & e(\mathbf{X}_2, \boldsymbol{\Theta}) & \dots & e(\mathbf{X}_N, \boldsymbol{\Theta}) \end{bmatrix}^\top. \quad (3.11)$$

Za kriterijsku funkciju definiranu izrazom (3.10) gradijentni vektor i Hessian matrica poprimaju sljedeće oblike:

$$\nabla \mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) = \mathbf{J}^\top(\mathbf{X}, \boldsymbol{\Theta}) \mathbf{e}(\mathbf{X}, \boldsymbol{\Theta}), \quad (3.12a)$$

$$\nabla^2 \mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) = \mathbf{J}^\top(\mathbf{X}, \boldsymbol{\Theta}) \mathbf{J}(\mathbf{X}, \boldsymbol{\Theta}) + \sum_{i=1}^N e(\mathbf{X}_i, \boldsymbol{\Theta}) \nabla^2 e(\mathbf{X}_i, \boldsymbol{\Theta}), \quad (3.12b)$$

gdje je $\mathbf{J}(\mathbf{X}, \boldsymbol{\Theta})$ Jacobijeva matrica definirana kako slijedi:

$$\nabla \mathbf{e}(\mathbf{X}, \boldsymbol{\Theta}) = \frac{\partial \mathbf{e}(\mathbf{X}, \boldsymbol{\Theta})}{\partial \boldsymbol{\Theta}} = \begin{bmatrix} \frac{\partial e(\mathbf{X}_1, \boldsymbol{\Theta})}{\partial \Theta_1} & \frac{\partial e(\mathbf{X}_1, \boldsymbol{\Theta})}{\partial \Theta_2} & \dots & \frac{\partial e(\mathbf{X}_1, \boldsymbol{\Theta})}{\partial \Theta_{n(\boldsymbol{\Theta})}} \\ \frac{\partial e(\mathbf{X}_2, \boldsymbol{\Theta})}{\partial \Theta_1} & \frac{\partial e(\mathbf{X}_2, \boldsymbol{\Theta})}{\partial \Theta_2} & \dots & \frac{\partial e(\mathbf{X}_2, \boldsymbol{\Theta})}{\partial \Theta_{n(\boldsymbol{\Theta})}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial e(\mathbf{X}_N, \boldsymbol{\Theta})}{\partial \Theta_1} & \frac{\partial e(\mathbf{X}_N, \boldsymbol{\Theta})}{\partial \Theta_2} & \dots & \frac{\partial e(\mathbf{X}_N, \boldsymbol{\Theta})}{\partial \Theta_{n(\boldsymbol{\Theta})}} \end{bmatrix}. \quad (3.13)$$

U točki $\boldsymbol{\Theta} = \boldsymbol{\Theta}^*$ bit će minimum funkcije $\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})$ ako su ispunjeni sljedeći uvjeti:

$$\left. \frac{\partial \mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})}{\partial \boldsymbol{\Theta}} \right|_{\boldsymbol{\Theta}=\boldsymbol{\Theta}^*} = 0, \quad (3.14a)$$

$$\Delta \boldsymbol{\Theta}^\top \nabla^2 \mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) \Delta \boldsymbol{\Theta} > 0. \quad (3.14b)$$

Ispunjene uvjete (3.14a) ukazuju da je u točki $\boldsymbol{\Theta}^*$ ekstrem kriterijske funkcije, međutim ne može se zaključiti je li minimum, maksimum ili sedlo. Ispunjene uvjete (3.14b) ukazuju da je u točki ekstrema $\boldsymbol{\Theta}^*$ minimum postavljenje kriterijske funkcije. Numerički postupci minimiziranja funkcije $\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})$ osiguravaju konvergenciju samo u lokalni minimum, što znači da minimizacijom dobivene vrijednosti parametara ne moraju biti jednake optimalnim vrijednostima $\boldsymbol{\Theta}^*$. Međutim, za većinu praktičnih primjena nije niti nužno pronaći parametre koji daju globalni minimum, već se zadovoljavajućom smatraju bilo koje vrijednosti parametara za koje kriterijska funkcija poprima dovoljno mali iznos, tj. za koje vrijedi:

$$\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta}) \leq \varepsilon, \quad (3.15)$$

gdje je $\varepsilon \in \mathbb{R}$ mala pozitivna konstanta.

Dva su osnovna načina minimiziranja kriterijske funkcije $\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})$ na kojima se temelje algoritmi učenja neuronskih mreža: (i) nerekurzivni i (ii) rekurzivni. Prema nerekurzivnom se načinu kriterijska funkcija $\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})$ minimizira tako da se promjene parametara mreže akumuliraju preko svih N vektora mjernih podataka i tek nakon toga se stvarno promijene parametri mreže. Prema rekurzivnom se načinu kriterijska funkcija $\mathfrak{J}(\mathbf{X}, \boldsymbol{\Theta})$ minimizira na temelju lokalne kriterijske funkcije $\mathfrak{J}_v(\mathbf{X}, \boldsymbol{\Theta})$, odnosno parametri mreže mijenjaju se nakon svakog vektora mjernih podataka.

U slučaju identifikacije modela potrošnje energije, mjerni podatci su unaprijed poznati pa će se prema tome za identifikaciju koristiti nerekurzivni način učenja. Većina nerekurzivnih algoritama učenja temelje se na standardnim postupcima nelinearnog optimiranja koji minimum ciljne funkcije traže na nerekurzivan način. Ciljna funkcija koju

algoritmi učenja neuronskih mreža trebaju minimizirati jest definirana kriterijska funkcija $\mathfrak{F}(\mathbf{X}, \Theta)$. Algoritmi učenja minimiziraju kriterijsku funkciju podešavanjem iznosa parametara mreže Θ . Najčešće korišteni algoritmi učenja neuronskih mreža zasnivaju se na iterativnom postupku [5]:

$$\Theta_{k+1} = \Theta_k + \Delta\Theta_k = \Theta_k + \alpha_k \mathbf{s}_{d,k}, \quad (3.16)$$

gdje je $\mathbf{s}_{d,k}$ smjer traženja minimuma u k -toj iteraciji koji se zasniva na informaciji o funkciji $\mathfrak{F}(\mathbf{X}, \Theta)$, a α_k koeficijent učenja u k -toj iteraciji koji određuje duljinu koraka u smjeru traženja.

Levenberg-Marquardtov algoritam zasniva se na prepostavci da se pogreška $\mathbf{e}(\mathbf{X}, \Theta)$ u okolini točke Θ_k može dovoljno dobro aproksimirati s prva dva člana Taylorovog reda:

$$\mathbf{e}(\mathbf{X}, \Theta) \approx \tilde{\mathbf{e}}(\mathbf{X}, \Theta) = \mathbf{e}(\mathbf{X}, \Theta_k) + \nabla \mathbf{e}(\mathbf{X}, \Theta)|_{\Theta=\Theta_k} \Delta\Theta_k, \quad (3.17)$$

pri čemu vrijedi $\Delta\Theta_k = \Theta - \Theta_k$.

Sada se umjesto minimiziranja kriterijske funkcije iz izraza (3.10) minimizira njezina aproksimacija definirana kao:

$$\tilde{\mathfrak{F}}(\mathbf{X}, \Theta) = \frac{1}{2} \tilde{\mathbf{e}}^\top(\mathbf{X}, \Theta) \tilde{\mathbf{e}}(\mathbf{X}, \Theta). \quad (3.18)$$

Iz uvjeta $\nabla \tilde{\mathfrak{F}}(\mathbf{X}, \Theta) = 0$ dobije se izraz koji minimizira funkciju (3.18):

$$\mathbf{J}^\top(\mathbf{X}, \Theta_k) \mathbf{J}(\mathbf{X}, \Theta_k) \Delta\Theta_k + \mathbf{J}^\top(\mathbf{X}, \Theta_k) \mathbf{e}(\mathbf{X}, \Theta_k) = 0, \quad (3.19)$$

Uvrštenjem izraza (3.12a) u izraz (3.19) uz $\Theta = \Theta_{k+1}$ te uvođenjem koeficijenta učenja α_k , dobije se sljedeći izraz za izračunavanje parametara mreže:

$$\Theta_{k+1} = \Theta_k - \alpha_k (\mathbf{H}(\mathbf{X}, \Theta_k))^{-1} \mathbf{J}^\top(\mathbf{X}, \Theta_k) \mathbf{e}(\mathbf{X}, \Theta_k). \quad (3.20)$$

U izrazu (3.20) Hessian matrica se zamjenjuje matricom:

$$\tilde{\mathbf{H}}(\mathbf{X}, \Theta_k) = \mathbf{J}^\top(\mathbf{X}, \Theta_k) \mathbf{J}(\mathbf{X}, \Theta_k), \quad (3.21)$$

koja je jednaka prvom članu Hessian matrice definirane izrazom (3.12b). Matrica $\tilde{\mathbf{H}}$ je pozitivno semidefinitna, što je dovoljan uvjet da algoritam (3.20) ne divergira. Međutim, ako mjerni podatci nisu dovoljno informativni ili ako neuronska mreža ima prevelik broj neurona, matrica $\tilde{\mathbf{H}}$ može postati loše kondicionirana, tj. skoro singularna ili singularna, što ima za posljedicu numeričku nestabilnost algoritma. Za prevladavanje ovih problema potrebno je matricu $\tilde{\mathbf{H}}$ dodatno promijeniti da se dobije pozitivno definitna

matrica u čitavom području vrijednosti kriterijske funkcije. Iz tih razloga izведен je novi, poboljšani izraz za izračunavanje parametara mreže [5]:

$$\boldsymbol{\Theta}_{k+1} = \boldsymbol{\Theta}_k - \left[\mathbf{J}^\top(\mathbf{X}, \boldsymbol{\Theta}_k) \mathbf{J}(\mathbf{X}, \boldsymbol{\Theta}_k) + \mu_k \mathbf{I} \right]^{-1} \mathbf{J}^\top(\mathbf{X}, \boldsymbol{\Theta}_k) \mathbf{e}(\mathbf{X}, \boldsymbol{\Theta}_k), \quad (3.22)$$

gdje parametar μ_k određuje veličinu promjene $\Delta\boldsymbol{\Theta}$.

U svakoj se iteraciji algoritma koeficijent μ_k određuje drugim iterativnim postupkom. Početni iznos koeficijenta μ_k određuje se množenjem njegova optimalnog iznosa iz prethodne iteracije algoritma koeficijentom smanjenja μ_d ($\mu_d < 1$), tj. $\mu_k = \mu_d \mu_{k-1}$, osim u prvoj iteraciji kada se koristi početna vrijednost μ_0 koju zadaje korisnik. Uz taj se iznos koeficijenta μ_k izračunava kriterijska funkcija i uspoređuje s njezinim iznosom u prethodnoj iteraciji. Ako se iznos kriterijske funkcije smanjio, iznos koeficijenta μ_k smatra se optimalnim i prelazi se na sljedeću iteraciju algoritma učenja mreže, a ako se iznos kriterijske funkcije povećao, iznos koeficijenta μ_k povećava se iterativno, množenjem s koeficijentom povećanja μ_i ($\mu_i > 1$) u svakom koraku, dok ne dođe do smanjenja kriterijske funkcije.

Odabrana struktura neuronske mreže ima ukupno $n(0)$ ulaznih signala, $n(1)$ neurona u skrivenom sloju te $n(2) = 1$ izlazni signal koji predstavlja radnu ili jalovu energiju. Vektor parametara mreže u tom slučaju je definiran kao:

$$\boldsymbol{\Theta} = \left[w_{s,1,1} \dots w_{s,1,n(0)+1}, \sigma_1, w_{t,1} \dots w_{t,n(1)+1} \right]^\top. \quad (3.23)$$

Konačni izraz koji opisuje odabranu strukturu umjetne MLP neuronske mreže, izведен na temelju izraza (3.3), (3.4a), (3.4b) i (3.5) je:

$$v_{2,1} = \sum_{i=1}^{n(1)} \psi_1(v_{1,i}, g_i) w_{t,i} + w_{t,n(1)+1}, \quad (3.24a)$$

$$f(\mathbf{X}, \boldsymbol{\Theta}) = \psi_2(v_{2,1}). \quad (3.24b)$$

pri čemu ψ_1 predstavlja Tansig funkciju, a ψ_2 Purelin linearu funkciju jediničnog pojačanja.

Uz ovako definiranu funkciju koja opisuje neuronsku mrežu, parcijalne derivacije funkcije $f(\mathbf{X}, \boldsymbol{\Theta})$ po parametrima i -tog neurona prema BP algoritmu su:

$$\begin{aligned} \frac{\partial f(\mathbf{X}, \boldsymbol{\Theta})}{\partial w_{s,i,k}} &= \frac{\partial \psi_2(v_{2,1})}{\partial v_{2,1}} \frac{\partial v_{2,1}}{\partial v_{1,i}} \frac{\partial v_{1,i}}{\partial w_{s,i,k}}, \\ \frac{\partial f(\mathbf{X}, \boldsymbol{\Theta})}{\partial g_i} &= \frac{\partial \psi_2(v_{2,1})}{\partial v_{2,1}} \frac{\partial v_{2,1}}{\partial g_i}, \\ \frac{\partial f(\mathbf{X}, \boldsymbol{\Theta})}{\partial w_{t,i}} &= \frac{\partial \psi_2(v_{2,1})}{\partial v_{2,1}} \frac{\partial v_{2,1}}{\partial w_{t,i}}. \end{aligned} \quad (3.25)$$

Uzme li se u obzir normiranje ulazno-izlaznih podataka, tada se parcijalne derivacije pogreške $\bar{e}(\bar{\mathbf{X}}_i, \bar{\Theta})$ po parametrima mreže mogu izračunati kao:

$$\frac{\partial \bar{e}(\bar{\mathbf{X}}_i, \bar{\Theta})}{\partial \bar{\Theta}} = \frac{1}{\mu} \frac{\partial f(\bar{\mathbf{X}}_i, \bar{\Theta})}{\partial \bar{\Theta}}. \quad (3.26)$$

Početne vrijednosti parametara neuronske mreže u velikoj mjeri utječu na brzinu konvergencije algoritma učenja, osobito u slučajevima kada se neuronska mreža koristi za aproksimaciju vrlo složenih nelinearnih funkcija. Velika slabost opisanog algoritma učenja, kao i svih ostalih gradijentnih algoritama, je pojava lokalnih minimuma u kriterijskoj funkciji.

POGLAVLJE 4

Rezultati identifikacije

Učenje neuronske mreže provedeno je na meteorološkim podacima preuzetim iz Državnog hidrometeorološkog zavoda i mjeranjima potrošnje električne energije na FER-u u razdoblju od 01.01.-31.12.2011. godine. Ulazni podaci korišteni pri učenju modela su (i) dan u godini, (ii) temperatura, (iii) vrijeme u danu i (iv) dozračenost. Kao izlazni podatak korištena su mjerena potrošnja električne energije na FER-u za radnu i jalovu energiju zasebno, prikazana na Slici 4.1. Mjerenja temperature i dozračenosti dostupna su u 10-minutnoj rezoluciji dok su mjerena potrošnje električne energije u 15-minutnoj rezoluciji. Iz tog razloga bilo je potrebno korištenjem srednjih vrijednosti temperature i dozračenosti unutar 10 minuta odabrati odgovarajuće vrijednosti i upariti ih s mjeranjima energije u podudarajućim minutama. Ulazni i izlazni podaci prvo su interpolirani na 1-minutnu rezoluciju da bi zatim bili integrirani na 15-minutnu rezoluciju. U koničnici dobiveno je sljedeće: uparene su mjerene vrijednosti temperature i dozračenosti za određenu minutu (ulazni podatak) s mjeranjem potrošnje energije na FER-u za istu minutu (izlazni podatak), sve u 15-minutnoj rezoluciji. Kao dodatni ulazni podaci korišteni su parametri koji neuronskoj mreži govore o kojoj se minuti kojega dana u godini radi. Zbog velikih razlika u vladanju potrošnje energije na FER-u između radnih i neradnih dana, identificirani su posebni modeli za radne i neradne dane.

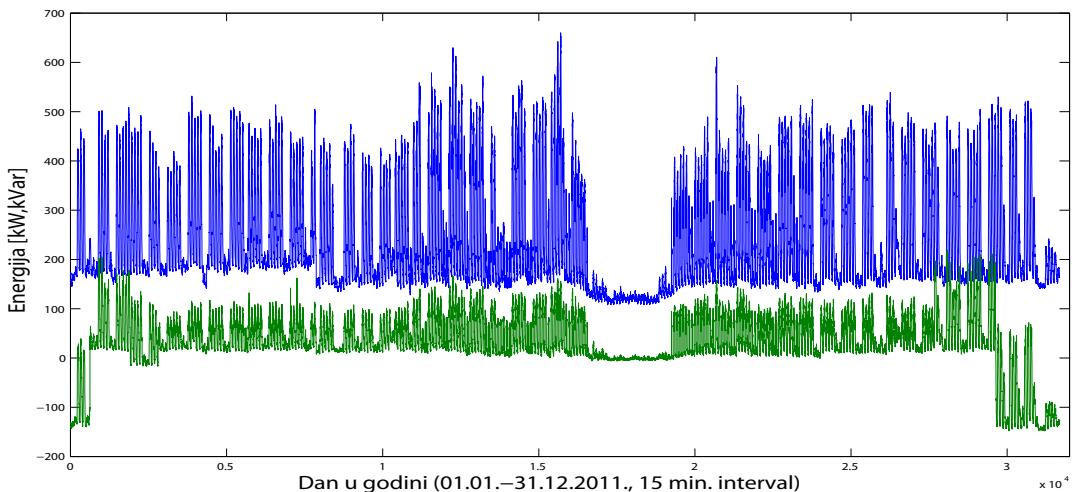
Za svaku komponentu električne energije (radnu i jalovu) identificirani su zasebni modeli. Pri tome su isprobane kombinacije s tansig, logsig i purelin aktivacijskim funkcijama da bi se ustvrdilo da je u prosjeku najtočnija varijanta s Tansig funkcijom u skrivenom i u izlaznom sloju, no kombinacija Tansig-Purelin dala je najbolji pojedinačni rezultat te se ona uzimala pri dalnjem učenju. Isprobane su i različite kombinacije ulaza modela pri čemu je varijanta sa sva četiri ulaza dala uvjerljivo najbolje rezultate. Radi jednostavnosti prikazani su rezultati samo najbolje identifikacije.

U Tablici 4.1 su prikazani iznosi pokazatelja kvalitete za identificirane modele na podatcima za učenje. Kvaliteta identificiranih modela provjerena je tzv. MBE¹ i RMSE² pokazateljima kvalitete, a koji su definirani kako slijedi:

$$\text{MBE} = \frac{1}{N} \sum_{i=1}^N e_i, \quad (4.1\text{a})$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N e_i^2}. \quad (4.1\text{b})$$

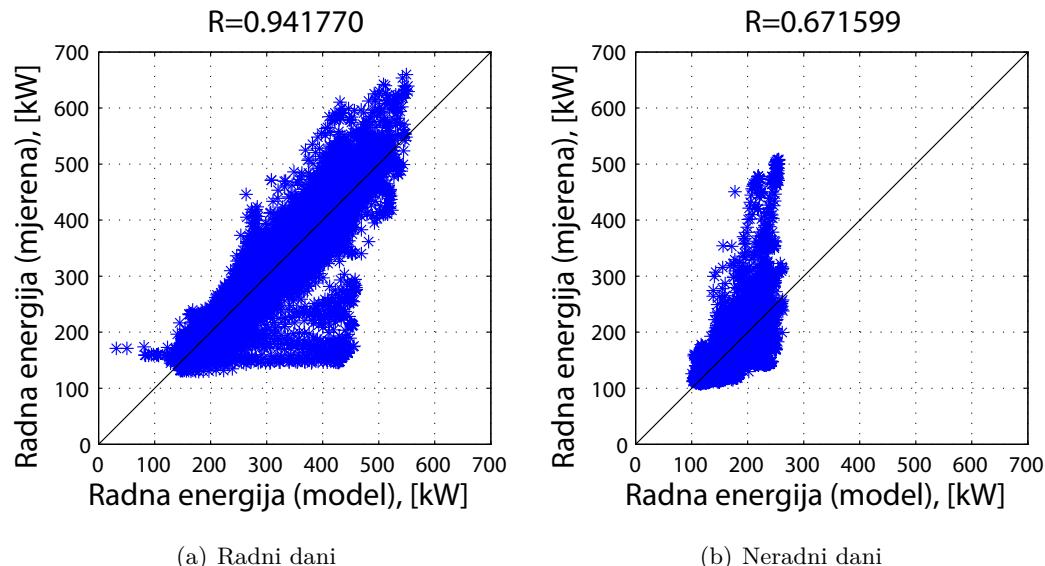
Odabir aktivacijskih funkcija je proveden kroz 50 učenja neuronske mreže, a odabir ulaza kroz dodatnih 70 učenja. Nakon potrebnih odabira učenje neuronske mreže za radnu energiju je provedeno kroz 20 učenja, od čega 10 za radne dane te 10 za neradne dane. Učenje neuronske mreže za jalovu energiju provedeno je također 20 puta, po 10 za radne i neradne dane. Na Slici 4.2 prikazani su najbolji rezultati dobiveni identifikacijom modela potrošnje radne energije, a na Slici 4.3 najbolji rezultati identifikacije modela jalove energije za radne i neradne dane. Kvaliteta rezultata izražena je regresijskom metodom koja pokazuje povezanost između mjerene potrošnje električne energije i potrošnje električne energije dobivene modelom. Što je iznos faktora regresije R bliži 1 bolja je povezanost mjerjenih vrijednosti i vrijednosti dobivenih modelom.



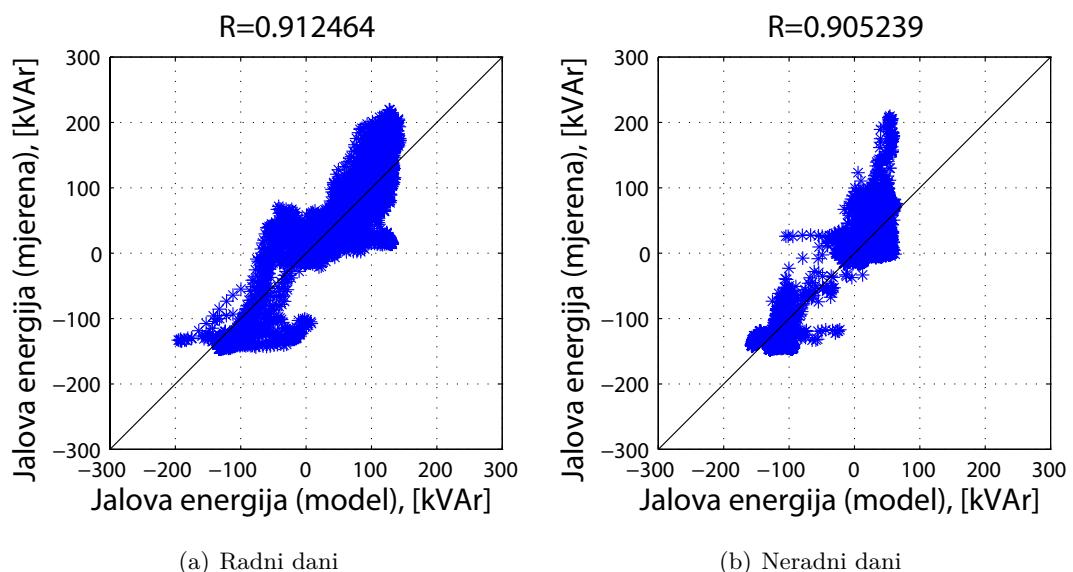
Slika 4.1: Potrošnja električne energije na Fakultetu Elektrotehnike i Računarstva u 2011. godini

¹engl. Mean Bias Error (MBE)

²engl. Root Mean Square Error (RMSE)



Slika 4.2: Rezultati učenja modela potrošnje radne energije



Slika 4.3: Rezultati učenja modela potrošnje jalove energije

Tablica 4.1: Pokazatelji kvalitete razvijenih modela

Model	Radna snaga		Jalova snaga	
	MBE	RMSE	MBE	RMSE
	0	31.7938	0.1687	50.4302
	0.1491	33.8172	0.3615	51.8362
	0.01064	34.3395	-0.0335	25.6599
MLP, 10n	0.007	34.5624	0	26.3211
Tansig-Purelin	-0.0211	34.7128	0.0016	27.3658
Radni dani	0.1329	34.0631	-0.0051	32.3779
	0.0182	34.3724	3.5890	51.2010
	0.0533	34.6255	-0.5350	29.5851
	0.0875	34.4707	6.4767	53.8499
	0.9197	41.5569	4.1750	55.4858
	-0.0253	20.5702	-0.8917	38.2310
	3.123	34.7193	-0.2002	40.3089
	-0.0471	27.2063	-0.1300	20.1452
MLP, 10n	1.2857	30.9732	-0.5312	35.7387
Tansig-Purelin	0.0195	20.7331	-0.3308	34.0642
Neradni dani	-0.1459	23.9486	1.2177	39.9988
	-0.1645	21.6463	0.2151	31.5037
	0.0013	20.5007	0.4903	43.03802
	-0.0504	27.1292	3.9636	50.4379
	-0.2642	22.8019	-1.6586	42.1670

Zaključak

U ovom radu prikazan je postupak razvoja modela potrošnje električne energije na Fakultetu elektrotehnike i računarstva Sveučilišta u Zagrebu, čijom se uporabom može predvidjeti potrošnja radne i jalove energije. U tu svrhu napravljena je identifikacija modela potrošnje radne energije primjenom MLP neuronske mreže s jednim skrivenim slojem i 10 neurona. Kao aktivacijska funkcija skrivenog sloja korištena je Tansig funkcija dok je u izlaznom sloju korištena Purelin funkcija. Identificirana su četiri različita modela. Dva za potrošnju radne energije (za radne i neradne dane) te dva za potrošnju jalove energije (za radne i neradne dane). Modeli potrošnje radne energije prilično se razlikuju u točnosti i njihovi faktori regresije iznose: $R = 0.94$ za radne dane i $R = 0.67$ za neradne dane. Faktori regresije modela potrošnje jalove energije približno su jednaki i iznose: $R = 0.91$ za radne dane i $R = 0.90$ za neradne dane.

Uporaba neuronskih mreža nije ograničena već se kao univerzalni aproksimatori mogu primijeniti za identifikaciju raznih modela i dobivaju poseban značaj pri upravljanju nelinearnim dinamičkim procesima. Predviđanje potrošnje električne energije od velike je važnosti jer kako se električna energija ne može pohranjivati u većim količinama, kvalitetna prognoza opterećenja uvelike može pomoći planiranju proizvodnje i/ili kupnje električne energije i na taj način omogućiti značajne financijske uštede. Predviđanje potrošnje također doprinosi planiranju i optimiranju proizvodnje električne energije te poboljšanju sigurnosti elektroenergetskog sustava. Predikcija profila potrošnje važna je i za optimizaciju rada agregata i spremnika električne energije u naprednim energetskim mrežama, tzv. mikromrežama.

LITERATURA

- [1] D. Mileta, B.Milešević, S. Sučić. Application of Neural Network for Zagreb Load Forecasting. 2012.
- [2] E.A Feinberg, D Genethliou. Chapter 12 Load forecasting. *Applied Mathematics for Power Systems*, pages 269–282.
- [3] F. Rosenblatt. *Principles of neurodynamics: Perceptrons and the theory of brain mechanisms*. Spartan Books, Washington, 1962.
- [4] H.S. Hippert, C.E. Pedreira, R.C. Souza. Neural Networks for Short-Term Load Forecasting: A Review and Evaluation. *IEEE Transactions on Power Systems*, 16:44–55, 2001.
- [5] I. Petrović. *Identifikacija nelinearnih dinamičkih procesa statickim neuronskim mrežama*. Fakultet Elektrotehnike i Računarstva, Zagreb, 1998. Doktorska disertacija.
- [6] K. Tačković, S. Nikolovski, V. Boras. Kratkoročno prognoziranje opterećenja primjenom modela umjetne neuronske mreže. *Energija*, 57:560–579, 2008.
- [7] M. Vašak, M. Gulin, J. Čeović, D. Nikolić, T. Pavlović, N. Perić. Meteorological and weather forecast data-based prediction of electrical power delivery of a photovoltaic panel in a stochastic framework. In *Proc. of. MIPRO*, 2011.

SAŽETAK

Naslov: Predviđanje potrošnje električne energije na Sveučilištu u Zagrebu Fakultetu elektrotehnike i računarstva višeslojnom perceptronском neuronskom mrežom

Autor: Hrvoje Novak

Predviđanje potrošnje električne energije ključno je za upravljanje i rad elektroenergetskih sustava. Donosi značajne finansijske uštede, pomaže pri planiranju proizvodnje i kupnje električne energije, pri razvoju infrastrukture, pri povećanju sigurnosti opskrbe električnom energijom i optimizaciji naprednih energetskih mreža (mikromreža). Zbog tih razloga razvijeni su brojni algoritmi namijenjeni što točnijem predviđanju potrošnje energije. Jedan od algoritama predviđanja potrošnje su neuronske mreže kao univerzalni aproksimatori proizvoljnih nelinearnih funkcija. Cilj ovog rada bilo je razviti višeslojnu perceptronsku neuronsku mrežu te ju primijeniti na predviđanju potrošnje električne energije na Sveučilištu u Zagrebu Fakultetu elektrotehnike i računarstva. Neuronska mreža je naučena na podacima iz 2011. godine.

Ključne riječi: Predviđanje potrošnje energije, Umjetne neuronske mreže, Identifikacija modela

ABSTRACT

Title: Forecasting of electrical energy consumption on University of Zagreb Faculty of Electrical Engineering and Computing with a multiple-layer perceptron neural network

Author: Hrvoje Novak

Forecasting of electrical energy consumption is essential for control and operation of energy systems. It results in significant financial savings, helps in planning production and purchase of electricity, in development of infrastructure, in increasing security of electricity supply and in optimization of smart energy grids (microgrids) . For these reasons, many algorithms have been developed with intentions to give a more accurate prediction of energy consumption. One of the algorithms are neural networks as universal approximators of nonlinear arbitrary functions. The aim of this study was to develop a multilayer perceptron neural network and apply it to prediction of electricity consumption on University of Zagreb Faculty of Electrical Engineering and Computing. The neural network has been learned on data from the 2011th year.

Keywords: Forecasting of electrical energy consumption, Artificial neural networks, Model identification

ŽIVOTOPIS

Rođen sam 15. siječnja 1991. godine u Zagrebu. Godine 2009. završio sam X. opću gimnaziju "Ivan Supek" u Zagrebu. Iste godine upisao sam se na Fakultetu elektrotehnike i računarstva u Zagrebu. Na drugoj godini studija upisao sam smjer Elektrotehnika i informacijska tehnologija, a na trećoj godini studija odabrao sam modul Elektroenergetika.